```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import yfinance as yf
import warnings

warnings.filterwarnings('ignore')
%matplotlib inline
sns.set_theme(style="whitegrid", palette="deep")
```

Descarga de datos históricos de Bitcoin

```
# Definimos el símbolo (ticker) de Bitcoin en Yahoo Finance
ticker = "BTC-USD"

# Definimos el rango de fechas que queremos descargar
start_date = "2015-01-01"          # Desde inicios de 2015 (Bitcoin ya tenía varios años)
end_date = "2025-02-20"            # Hasta una fecha cercana a hoy (Se puede poner None para la fecha actual)

# Descargamos los datos
print(f"Descargando datos de {ticker} desde {start_date} hasta {end_date}")
```

```
Descargando datos de BTC-USD desde 2015-01-01 hasta 2025-02-20
```

```
df = yf.download(
    tickers = ticker,              # El símbolo que queremos
    start = start_date,            # Fecha de inicio
    end = end_date,                # Fecha de fin (opcional, si no se pone → hasta hoy)
    interval = "1d",               # Intervalo: 1 día (diario) → ideal para empezar
    auto_adjust = True,            # Ajusta automáticamente precios por splits/dividendos (útil aunque en crypto casi no ap
    progress = True              # Muestra una barra de progreso (puedes poner False si molesta)
)

# Si todo salió bien, mostramos información básica
print("\nDescarga completada.")
print(f"Forma del DataFrame:{df.shape[0]} filas, {df.shape[1]} columnas")
print("\nPrimeras 5 filas del dataset:")
display(df.head())                 # display() es mejor que print() en Jupyter/Colab

print("\nÚltimas 5 filas (datos más recientes):")
display(df.tail())
```

```
[*********************100%***********************]  1 of 1 completed
Descarga completada.
Forma del DataFrame:3703 filas, 5 columnas

Primeras 5 filas del dataset:
```

Price	Close	High	Low	Open	Volume
Ticker	BTC-USD	BTC-USD	BTC-USD	BTC-USD	BTC-USD
Date					
2015-01-01	314.248993	320.434998	314.002991	320.434998	8036550
2015-01-02	315.032013	315.838989	313.565002	314.079010	7860650
2015-01-03	281.082001	315.149994	281.082001	314.846008	33054400
2015-01-04	264.195007	287.230011	257.612000	281.145996	55629100
2015-01-05	274.473999	278.341003	265.084015	265.084015	43962800

```
Últimas 5 filas (datos más recientes):
```

Price	Close	High	Low	Open	Volume
Ticker	BTC-USD	BTC-USD	BTC-USD	BTC-USD	BTC-USD
Date					
2025-02-15	97580.351562	97975.039062	97240.195312	97508.382812	17047266288
2025-02-16	96175.031250	97725.593750	96060.976562	97580.492188	16536755396
2025-02-17	95773.382812	97032.234375	95243.546875	96179.007812	27336550690
2025-02-18	95539.546875	96695.375000	93388.835938	95773.812500	37325720482
2025-02-19	96635.609375	96855.593750	95011.968750	95532.531250	28990872862

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
DatetimeIndex: 3703 entries, 2015-01-01 to 2025-02-19
Data columns (total 5 columns):
 #   Column             Non-Null Count  Dtype
---  ------             --------------  -----
 0   (Close, BTC-USD)   3703 non-null   float64
 1   (High, BTC-USD)    3703 non-null   float64
 2   (Low, BTC-USD)     3703 non-null   float64
 3   (Open, BTC-USD)    3703 non-null   float64
 4   (Volume, BTC-USD)  3703 non-null   int64
dtypes: float64(4), int64(1)
memory usage: 173.6 KB
```

```
df.describe()
```

Price	Close	High	Low	Open	Volume
Ticker	BTC-USD	BTC-USD	BTC-USD	BTC-USD	BTC-USD
count	3703.000000	3703.000000	3703.000000	3703.000000	3.703000e+03
mean	21207.593283	21654.781384	20691.005147	21182.897033	1.953101e+10
std	23853.656356	24334.841619	23300.680480	23825.737097	2.074962e+10
min	178.102997	211.731003	171.509995	176.897003	7.860650e+06
25%	2708.039917	2774.635010	2632.105103	2699.185059	1.300945e+09
50%	9842.666016	10074.238281	9600.728516	9823.429688	1.584821e+10
75%	34375.361328	35224.371094	33374.716797	34307.302734	3.060972e+10
max	106146.265625	109114.882812	105291.734375	106147.296875	3.509679e+11

```
# Comprbamos visualmente que no haya datos faltantes
df.isna().sum()
```

Price	Ticker	0
Close	BTC-USD	0
High	BTC-USD	0
Low	BTC-USD	0
Open	BTC-USD	0
Volume	BTC-USD	0

dtype: int64

Limpieza rápida: Simplificar nombres de columnas

```
# Como yfinance devuelve MultiIndex, quitamos el indice que no nos interesa → BTC-USD
df.columns = df.columns.get_level_values(0)

print("Columnas después de limpiar:")
print(df.columns.tolist())
```

```
Columnas después de limpiar:
['Close', 'High', 'Low', 'Open', 'Volume']
```

```
# Vista rápida de nuevo
display(df.head(3))
display(df.tail(3))
```

Price	Close	High	Low	Open	Volume
Date					
2015-01-01	314.248993	320.434998	314.002991	320.434998	8036550
2015-01-02	315.032013	315.838989	313.565002	314.079010	7860650
2015-01-03	281.082001	315.149994	281.082001	314.846008	33054400

Price	Close	High	Low	Open	Volume
Date					
2025-02-17	95773.382812	97032.234375	95243.546875	96179.007812	27336550690
2025-02-18	95539.546875	96695.375000	93388.835938	95773.812500	37325720482
2025-02-19	96635.609375	96855.593750	95011.968750	95532.531250	28990872862

Verificación: Duplicados y continuidad de fechas

```
# Duplicados completos (filas idénticas en TODAS las columnas)
duplicados_completos = df.duplicated().sum()
print(f"Filas duplicadas completas (idénticas en todas las columnas): {duplicados_completos}")

# Duplicados por fecha (mismo índice de fecha)
duplicados_por_fecha = df.index.duplicated().sum()
print(f"Fechas duplicadas en el índice: {duplicados_por_fecha}")

if duplicados_por_fecha > 0:
    print("Fechas duplicadas encontradas. Mostrando las primeras:")
    display(df[df.index.duplicated(keep=False)].head(6))
else:
    print("→ No hay fechas duplicadas.")
```

```
Filas duplicadas completas (idénticas en todas las columnas): 0
Fechas duplicadas en el índice: 0
→ No hay fechas duplicadas.
```

```
# Verificar continuidad de fechas (diferencias de 1 día)
# Creamos una serie con la diferencia en días entre fechas consecutivas
diff_fechas = df.index.to_series().diff().dt.days

# Quitamos el primer NaT (porque no hay anterior)
diff_fechas = diff_fechas.dropna()

# ¿Cuántas diferencias NO son exactamente 1 día?
huecos = (diff_fechas != 1).sum()
print(f"\nNúmero de saltos/huecos (diferencia ≠ 1 día): {huecos}")
```

```
if huecos > 0:
    print("Fechas donde hubo salto (diferencia > 1 día):")
    # Mostramos las fechas problemáticas
    problematicas = diff_fechas[diff_fechas != 1]
    for fecha, dias in problematicas.items():
        print(f"  → Entre {fecha - pd.Timedelta(days=dias)} y {fecha}: {dias} días de diferencia")
else:
    print("→ Todas las fechas son consecutivas (diferencia = 1 día). ¡Excelente!")

# Resumen final
print("\nResumen de integridad:")
print(f"• Filas totales: {len(df)}")
print(f"• Fechas únicas: {df.index.nunique()}")
print(f"• Período: desde {df.index.min().date()} hasta {df.index.max().date()}")
print(f"• Días esperados aproximados: {(df.index.max() - df.index.min()).days + 1}")
```

```
Número de saltos/huecos (diferencia ≠ 1 día): 0
→ Todas las fechas son consecutivas (diferencia = 1 día). ¡Excelente!

Resumen de integridad:
• Filas totales: 3703
• Fechas únicas: 3703
• Período: desde 2015-01-01 hasta 2025-02-19
• Días esperados aproximados: 3703
```

Primer EDA visual: Evolución del precio de cierre (Close)

```
plt.figure(figsize=(14, 7))

# Graficamos Close
plt.plot(df.index, df['Close'], label='Precio de Cierre (USD)', color='royalblue', linewidth=1.2)

# Añadimos medias móviles simples (opcional pero muy útil)
df['MA_30'] = df['Close'].rolling(window=30).mean()
df['MA_200'] = df['Close'].rolling(window=200).mean()

plt.plot(df.index, df['MA_30'], label='Media Móvil 30 días', color='orange', linewidth=1.5)
plt.plot(df.index, df['MA_200'], label='Media Móvil 200 días', color='red', linewidth=2)

plt.title('Evolución histórica del precio de Bitcoin (BTC-USD) – Cierre diario', fontsize=16)
plt.xlabel('Fecha', fontsize=12)
plt.ylabel('Precio (USD)', fontsize=12)
plt.legend()
plt.grid(True,
         color='gray',
         linestyle='-',
         linewidth=0.8,
         alpha=0.7)
plt.tight_layout()
plt.show()
```

Retornos diarios

```
# Retorno simple diario (porcentaje)
df['Return_simple'] = df['Close'].pct_change() * 100

# Retorno logarítmico diario (más común en modelado financiero)
df['Return_log'] = np.log(df['Close'] / df['Close'].shift(1)) * 100

# Primeras filas para verificar
print("Primeras filas con retornos:")
display(df[['Close', 'Return_simple', 'Return_log']].head(8))

# Estadísticas básicas de los retornos
print("\nEstadísticas de retornos diarios (%):")
display(df[['Return_simple', 'Return_log']].describe().round(4))

# Asimetría y curtosis (útil para entender la distribución)
print("\nAsimetría (skew) y curtosis de retornos log:")
print(df['Return_log'].skew().round(4), "(skew)")
print(df['Return_log'].kurtosis().round(4), "(kurtosis)")
```

```
Primeras filas con retornos:
```

Price	Close	Return_simple	Return_log
Date			
2015-01-01	314.248993	NaN	NaN
2015-01-02	315.032013	0.249172	0.248862
2015-01-03	281.082001	-10.776686	-11.402782
2015-01-04	264.195007	-6.007853	-6.195895
2015-01-05	274.473999	3.890684	3.816904
2015-01-06	286.188995	4.268163	4.179588
2015-01-07	294.337006	2.847073	2.807297
2015-01-08	283.348999	-3.733138	-3.804604

```
Estadísticas de retornos diarios (%):
```

Price	Return_simple	Return_log
count	3702.0000	3702.0000
mean	0.2206	0.1547
std	3.6110	3.6372
min	-37.1695	-46.4730
25%	-1.2182	-1.2256
50%	0.1320	0.1319
75%	1.6720	1.6582
max	25.2472	22.5119

```
Asimetría (skew) y curtosis de retornos log:
-0.752 (skew)
11.6585 (kurtosis)
```

Visualización - Distribución de retornos logarítmicos

```
fig, axes = plt.subplots(1, 2, figsize=(14, 5))

# Histograma + KDE
sns.histplot(df['Return_log'].dropna(),
             kde=True,
             ax=axes[0],
             color='royalblue',
             bins=120)
axes[0].set_title('Distribución de retornos logarítmicos diarios (%)')
axes[0].set_xlabel('Retorno log diario (%)')
axes[0].set_ylabel('Frecuencia')

# Boxplot (para ver outliers)
sns.boxplot(x=df['Return_log'].dropna(),
            ax=axes[1],
            color='lightblue',
            width=0.4)
axes[1].set_title('Boxplot - Retornos log diarios')
axes[1].set_xlabel('Retorno log diario (%)')

plt.tight_layout()
plt.show()
```

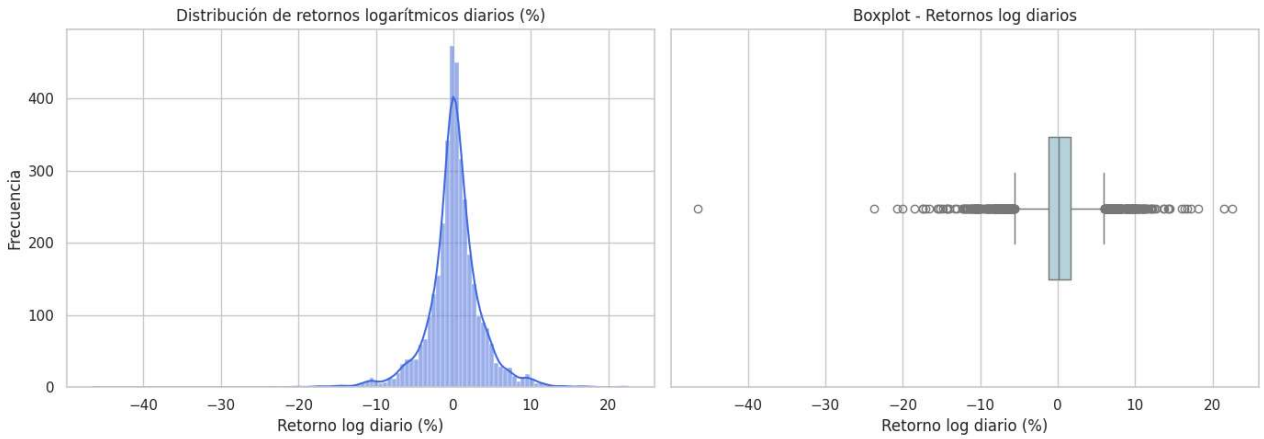

Volatilidad rolling (desviación estándar anualizada aproximada)

```
# Volatilidad rolling
window_30  = 30
window_90  = 90

df['Vol_30d'] = df['Return_log'].rolling(window=window_30).std() * np.sqrt(365)
df['Vol_90d'] = df['Return_log'].rolling(window=window_90).std() * np.sqrt(365)

plt.figure(figsize=(15, 6))

plt.plot(df['Vol_30d'], label=f'Volatilidad rolling {window_30}d (anualizada)', color='purple', lw=1.4)
plt.plot(df['Vol_90d'], label=f'Volatilidad rolling {window_90}d (anualizada)', color='darkorange', lw=1.8)

plt.title('Volatilidad histórica rolling de Bitcoin (anualizada)', fontsize=15)
plt.ylabel('Volatilidad anualizada (%)')
plt.grid(True, alpha=0.5)
plt.legend()
plt.tight_layout()
plt.show()
```

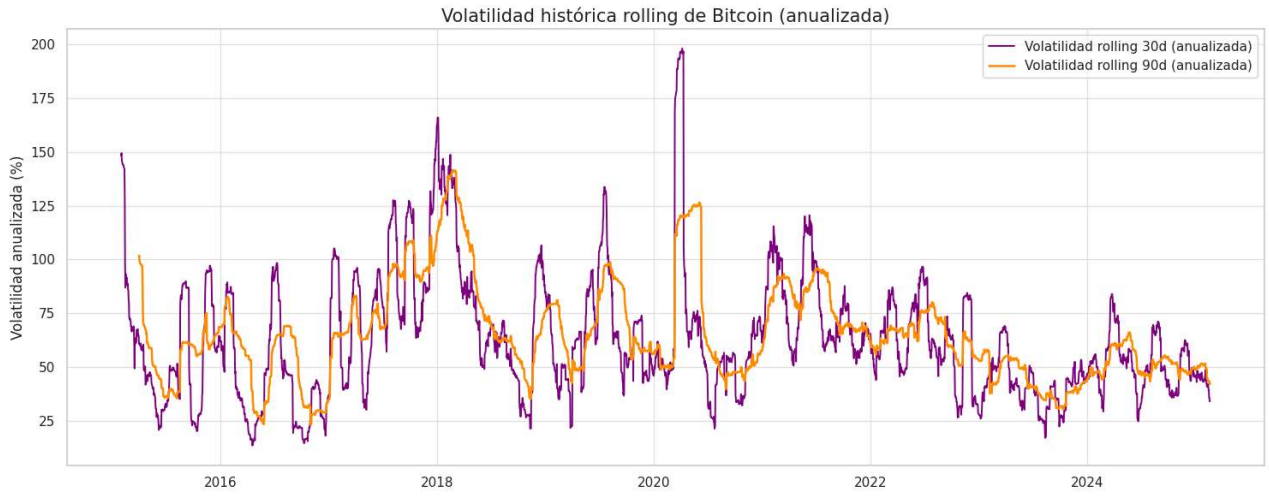

Volumen + precio

```
fig, ax1 = plt.subplots(figsize=(15, 7))

ax1.plot(df['Close'], color='royalblue', label='Precio Close', lw=1.2)
ax1.set_ylabel('Precio (USD)', color='royalblue')
ax1.tick_params(axis='y', labelcolor='royalblue')

ax2 = ax1.twinx()
```

```
ax2.bar(df.index, df['Volume'], color='gray', alpha=0.35, width=1.0, label='Volumen')
ax2.set_ylabel('Volumen', color='gray')
ax2.tick_params(axis='y', labelcolor='gray')

plt.title('Precio vs Volumen negociado (diario)', fontsize=15)
fig.legend(loc='upper left', bbox_to_anchor=(0.13, 0.88))
plt.tight_layout()
plt.show()
```

Boxplot de retornos por año

```
df['Year'] = df.index.year

plt.figure(figsize=(12, 6))
sns.boxplot(x='Year', y='Return_log', data=df, palette='viridis')
plt.title('Distribución de retornos logarítmicos diarios por año')
plt.ylabel('Retorno log diario (%)')
plt.grid(True, axis='y', alpha=0.4)
plt.tight_layout()

plt.show()
```

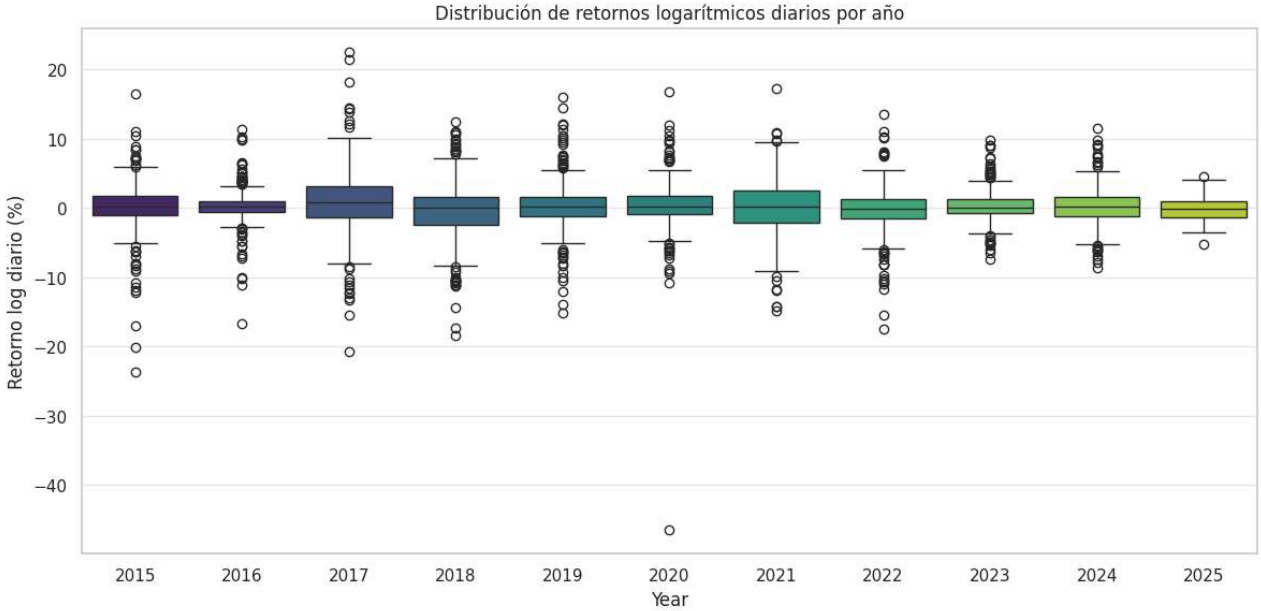

Preparación para modelado: Target y features de rezago

```
horizon = 7   # ← CAMBIAR AQUÍ según se elija (días adelante)

# Target: precio de cierre dentro de 'horizon' días
df['Target'] = df['Close'].shift(-horizon)

# Features de rezago: precios y retornos pasados
lags = [1, 3, 7, 14, 30]   # puedes ajustar estos valores

for lag in lags:
    df[f'Close_lag_{lag}']  = df['Close'].shift(lag)
    df[f'Return_log_lag_{lag}'] = df['Return_log'].shift(lag)
    df[f'Vol_30d_lag_{lag}'] = df['Vol_30d'].shift(lag)

# Otras features útiles (opcionales pero recomendadas)
df['Day_of_week'] = df.index.dayofweek      # 0 = lunes, 6 = domingo
df['Month']       = df.index.month
df['Quarter']     = df.index.quarter

# Eliminamos filas con NaN (las últimas 'horizon' filas no tienen target, y primeras por lags)
df_model = df.dropna().copy()

print(f"Filas disponibles para modelado: {len(df_model):,}")
print(f"Período modelable: {df_model.index.min().date()} → {df_model.index.max().date()}")
print("\nColumnas disponibles ahora:")
print(df_model.columns.tolist())

# Vista rápida
display(df_model[['Close', 'Target'] + [c for c in df_model.columns if 'lag' in c]].tail(8))
```

```
Filas disponibles para modelado: 3,497
Período modelable: 2015-07-19 → 2025-02-12

Columnas disponibles ahora:
['Close', 'High', 'Low', 'Open', 'Volume', 'MA_30', 'MA_200', 'Return_simple', 'Return_log', 'Vol_30d', 'Vol_90d', 'Year', '
```

Price	Close	Target	Close_lag_1	Return_log_lag_1	Vol_30d_lag_1	Close_lag_3	Return_log_lag_3	Vol_30d_lag
Date								
2025-02-05	96615.445312	97885.859375	97871.820312	-3.546789	48.694546	97688.976562	-2.991911	45.1405
2025-02-06	96593.296875	96623.867188	96615.445312	-1.292005	46.925319	101405.421875	3.733784	46.9974
2025-02-07	96529.085938	97508.968750	96593.296875	-0.022927	43.319736	97871.820312	-3.546789	48.6945
2025-02-08	96482.453125	97580.351562	96529.085938	-0.066498	42.748658	96615.445312	-1.292005	46.9253
2025-02-09	96500.093750	96175.031250	96482.453125	-0.048321	41.559292	96593.296875	-0.022927	43.3197
2025-02-10	97437.554688	95773.382812	96500.093750	0.018282	40.774431	96529.085938	-0.066498	42.7486
2025-02-11	95747.429688	95539.546875	97437.554688	0.966773	40.887588	96482.453125	-0.048321	41.5592
2025-02-12	97885.859375	96635.609375	95747.429688	-1.749792	41.391575	96500.093750	0.018282	40.7744

División cronológica (85% train - 15% test)

```
train_pct = 0.85
n_train = int(len(df_model) * train_pct)

df_train = df_model.iloc[:n_train].copy()
df_test  = df_model.iloc[n_train:].copy()

print(f"Train: {len(df_train):,} filas → {df_train.index.min().date()} → {df_train.index.max().date()}")
print(f"Test:  {len(df_test):,} filas  → {df_test.index.min().date()} → {df_test.index.max().date()}")

# Variables predictoras (X) y objetivo (y)
features = [c for c in df_model.columns if 'lag' in c or c in ['Day_of_week', 'Month', 'Quarter', 'Vol_30d', 'Vol_90d']]

X_train = df_train[features]
y_train = df_train['Target']

X_test  = df_test[features]
y_test  = df_test['Target']

print(f"\nNúmero de features: {len(features)}")
print("Ejemplo de features:", features[:8])
```

```
Train: 2,972 filas → 2015-07-19 → 2023-09-06
Test:  525 filas  → 2023-09-07 → 2025-02-12

Número de features: 20
Ejemplo de features: ['Vol_30d', 'Vol_90d', 'Close_lag_1', 'Return_log_lag_1', 'Vol_30d_lag_1', 'Close_lag_3', 'Return_log_l
```

Modelo 1: Naive - Predicción = último precio conocido

```
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score

# Predicción naive: el precio de hace 7 días (porque horizonte=7)
# Es decir: para predecir t+7 usamos Close de t
df_test['Naive_Pred'] = df_test['Close_lag_7']   # ya lo tenemos calculado

# Métricas
mae_naive   = mean_absolute_error(df_test['Target'], df_test['Naive_Pred'])
rmse_naive  = np.sqrt(mean_squared_error(df_test['Target'], df_test['Naive_Pred']))
r2_naive    = r2_score(df_test['Target'], df_test['Naive_Pred'])

print("Baseline Naive (último valor conocido - shift 7 días)")
print(f"MAE:   {mae_naive:,.2f} USD")
print(f"RMSE:  {rmse_naive:,.2f} USD")
print(f"R²:    {r2_naive:.4f}")
```

```
Baseline Naive (último valor conocido - shift 7 días)
MAE:   4,582.50 USD
RMSE:  6,240.04 USD
R²:    0.9141
```

```
# Gráfico comparativo rápido
plt.figure(figsize=(14, 6))
plt.plot(df_test.index, df_test['Target'], label='Real (t+7)', color='royalblue', lw=1.5)
plt.plot(df_test.index, df_test['Naive_Pred'], label='Naive Pred', color='gray', lw=1.2, ls='--')
plt.title('Baseline Naive vs Real – Test set (horizonte 7 días)')
plt.ylabel('Precio USD')
plt.legend()
plt.grid(alpha=0.4)
plt.tight_layout()
plt.show()
```

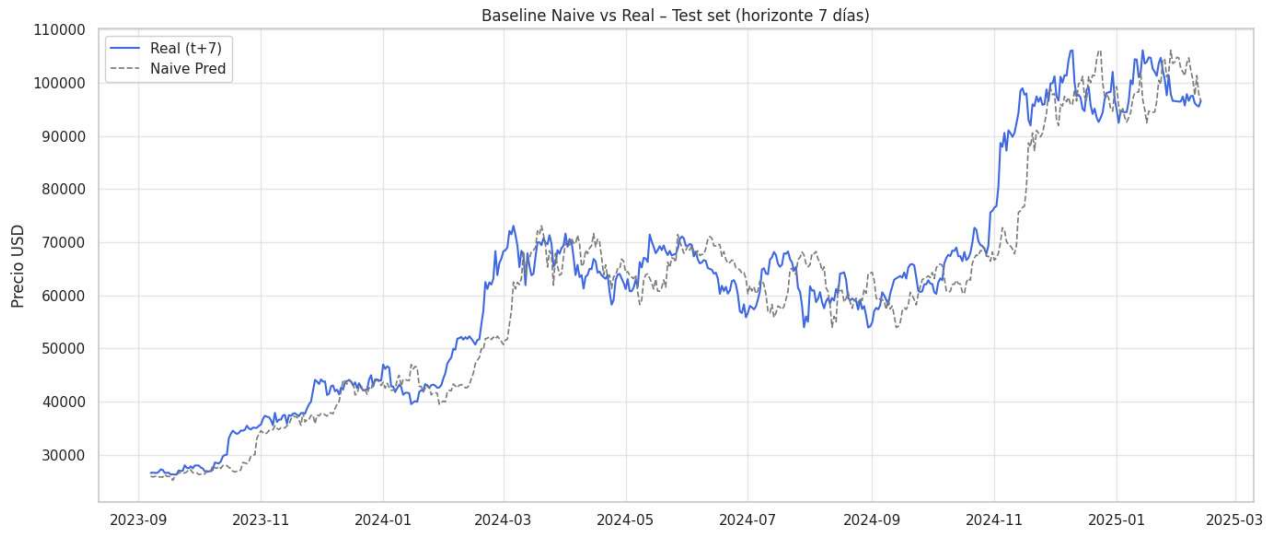

Modelo 2: Media Móvil 30 días (usamos la MA_30 como predicción)

```
df_test['MA30_Pred'] = df_test['MA_30']

mae_ma30   = mean_absolute_error(df_test['Target'], df_test['MA30_Pred'])
rmse_ma30  = np.sqrt(mean_squared_error(df_test['Target'], df_test['MA30_Pred']))
r2_ma30    = r2_score(df_test['Target'], df_test['MA30_Pred'])

print("Baseline Media Móvil 30 días persistente")
print(f"MAE:   {mae_ma30:,.2f} USD")
print(f"RMSE:  {rmse_ma30:,.2f} USD")
print(f"R²:    {r2_ma30:.4f}")
```

```
Baseline Media Móvil 30 días persistente
MAE:   5,215.68 USD
RMSE:  7,076.66 USD
R²:    0.8895
```

```
# Gráfico
plt.figure(figsize=(14, 6))
plt.plot(df_test.index, df_test['Target'], label='Real (t+7)', color='royalblue', lw=1.5)
plt.plot(df_test.index, df_test['MA30_Pred'], label='MA30 Pred', color='orange', lw=1.4, ls='--')
plt.title('Baseline MA30 vs Real – Test set (horizonte 7 días)')
plt.ylabel('Precio USD')
plt.legend()
plt.grid(alpha=0.4)
plt.tight_layout()
plt.show()
```

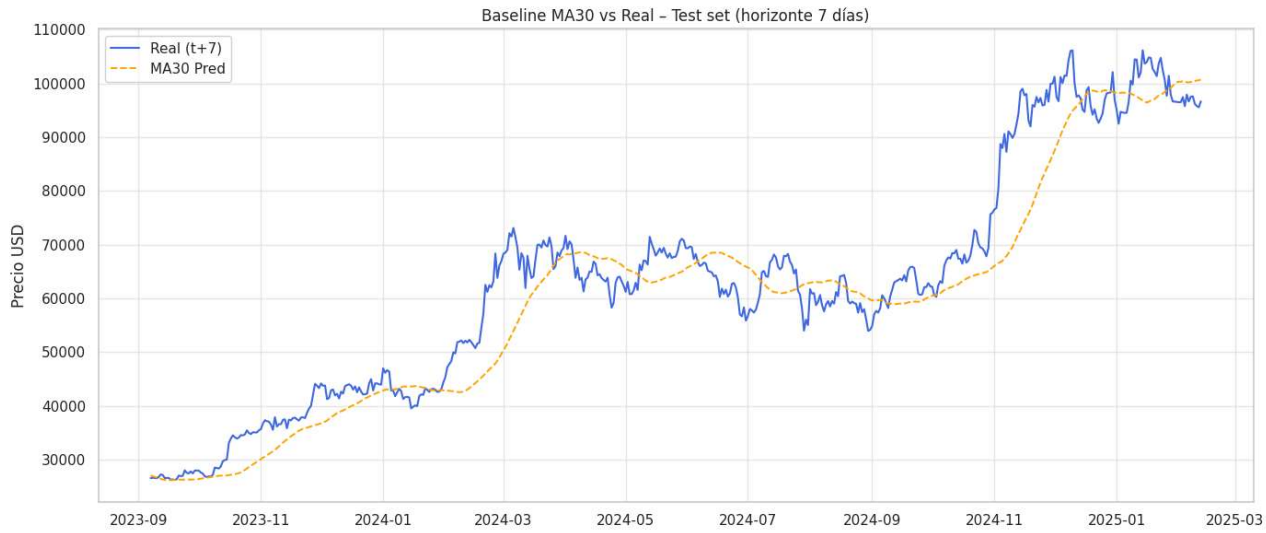

Mejora del modelo – Exponential Moving Average (EMA)

```
# EMA 7 días (más reactiva a cambios recientes)
df_test['EMA_7'] = df_test['Close'].ewm(span=7, adjust=False).mean()

# EMA 14 días (balance entre reactividad y suavizado)
df_test['EMA_14'] = df_test['Close'].ewm(span=14, adjust=False).mean()

# Métricas para EMA 7
mae_ema7  = mean_absolute_error(df_test['Target'], df_test['EMA_7'])
rmse_ema7 = np.sqrt(mean_squared_error(df_test['Target'], df_test['EMA_7']))
r2_ema7   = r2_score(df_test['Target'], df_test['EMA_7'])

# Métricas para EMA 14
mae_ema14  = mean_absolute_error(df_test['Target'], df_test['EMA_14'])
rmse_ema14 = np.sqrt(mean_squared_error(df_test['Target'], df_test['EMA_14']))
r2_ema14   = r2_score(df_test['Target'], df_test['EMA_14'])

print("Baseline EMA 7 días persistente")
print(f"MAE:   {mae_ema7:,.2f} USD")
print(f"RMSE:  {rmse_ema7:,.2f} USD")
print(f"R²:    {r2_ema7:.4f}\n")

print("Baseline EMA 14 días persistente")
print(f"MAE:   {mae_ema14:,.2f} USD")
print(f"RMSE:  {rmse_ema14:,.2f} USD")
print(f"R²:    {r2_ema14:.4f}")
```

```
Baseline EMA 7 días persistente
MAE:   3,495.79 USD
RMSE:  4,763.49 USD
R²:    0.9499

Baseline EMA 14 días persistente
MAE:   3,969.04 USD
RMSE:  5,350.24 USD
R²:    0.9369
```

```
# Gráfico comparativo
plt.figure(figsize=(15, 7))
plt.plot(df_test.index, df_test['Target'], label='Real (t+7)', color='royalblue', lw=1.5, alpha=0.9)
plt.plot(df_test.index, df_test['Naive_Pred'], label='Naive shift-7', color='gray', lw=1.2, ls='--')
plt.plot(df_test.index, df_test['EMA_7'], label='EMA 7 días', color='purple', lw=1.6)
plt.plot(df_test.index, df_test['EMA_14'], label='EMA 14 días', color='darkorange', lw=1.6)
plt.title('Baselines EMA vs Naive vs Real – Test set (horizonte 7 días)')
plt.ylabel('Precio USD')
plt.legend()
plt.grid(alpha=0.4)
plt.tight_layout()
plt.show()
```

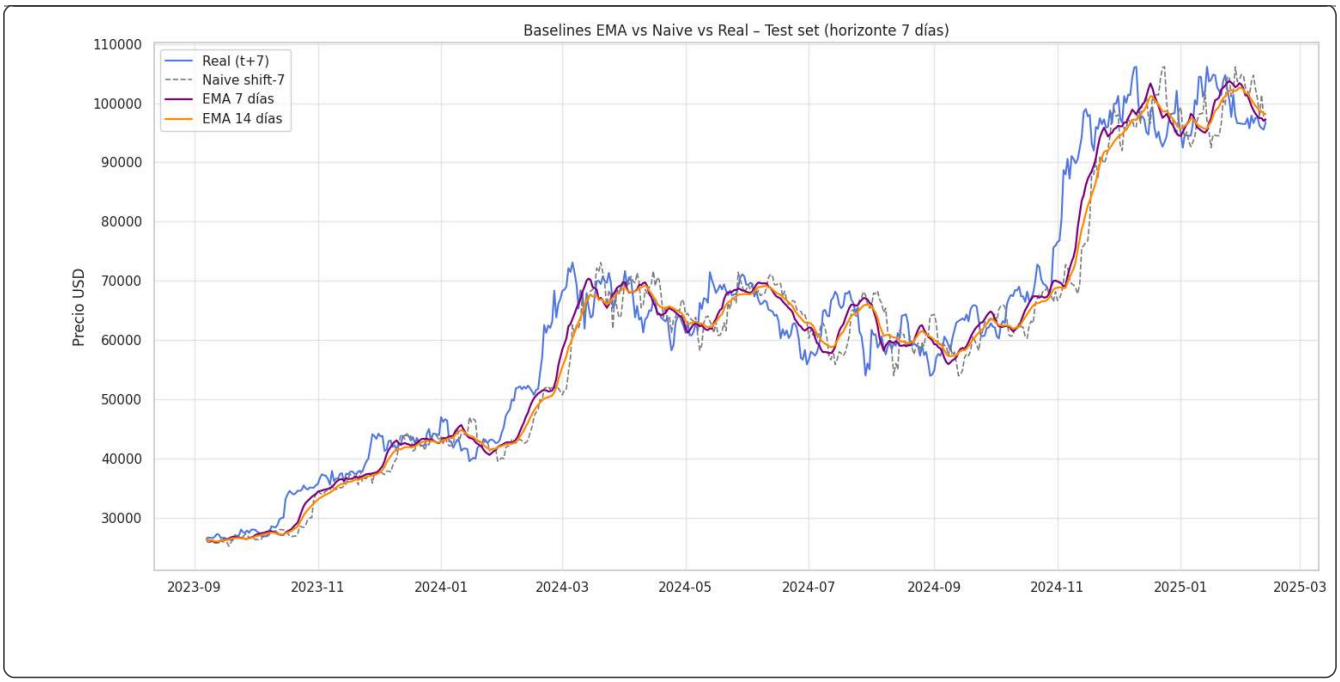

Modelo ML: XGBoost Regressor con features de rezago

```
import xgboost as xgb
```